

Machine Learning Formulas

MingShun Wu

October 6, 2016

Contents

| | | |
|-------|---|---|
| 1 | 线性回归(Linear Regression) | 3 |
| 1.1 | 各向量形式 | 3 |
| 1.2 | 批梯度下降 | 3 |
| 1.2.1 | 各矩阵形式 | 3 |
| 1.2.2 | Cost Function | 4 |
| 1.2.3 | 偏导数 $\frac{\partial J(\theta)}{\partial \theta_j}$ 计算 | 4 |
| 1.2.4 | 梯度下降迭代方式 | 5 |
| 1.3 | Feature Normalization | 5 |
| 1.4 | 公式法求解 (Normal Equation) | 5 |
| 2 | 逻辑回归(Logistic Regression) | 6 |
| 2.1 | 当只有2个类别时, 使用1个分类器 | 6 |
| 2.1.1 | 预测函数 | 6 |
| 2.1.2 | Cost Function | 6 |
| 2.1.3 | 梯度下降 | 6 |
| 2.2 | 当只有k个类别时, 使用k个分类器 | 6 |

1 线性回归(Linear Regression)

1.1 各向量形式

在机器学习中，各个变量在单独出现时均为列向量的形式，但若是以多个向量形成的矩阵形式出现时，均为行向量的形式。

以下将会写出各个变量单独出现的情况、各变量以矩阵的形式一起出现的情况。

1. \vec{x}

$$\vec{x} = \begin{pmatrix} x_0 \\ x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}_{(n+1)*1} \quad (1)$$

2. $\vec{\theta}$

$$\vec{\theta} = \begin{pmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{pmatrix}_{(n+1)*1} \quad (2)$$

3. \vec{y}

$$\vec{y} = (y)_{1*1} \quad (3)$$

1.2 批梯度下降

1.2.1 各矩阵形式

下述式子中均为矩阵的形式

1. X

$$\begin{aligned} X &= \begin{pmatrix} \vec{x}^{(1)} \\ \vec{x}^{(2)} \\ \vec{x}^{(3)} \\ \vdots \\ \vec{x}^{(m)} \end{pmatrix} \\ &= \begin{pmatrix} x_0^{(1)} & x_1^{(1)} & x_2^{(1)} & x_3^{(1)} & \dots & x_n^{(1)} \\ x_0^{(2)} & x_1^{(2)} & x_2^{(2)} & x_3^{(2)} & \dots & x_n^{(2)} \\ x_0^{(3)} & x_1^{(3)} & x_2^{(3)} & x_3^{(3)} & \dots & x_n^{(3)} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ x_0^{(m)} & x_1^{(m)} & x_2^{(m)} & x_3^{(m)} & \dots & x_n^{(m)} \end{pmatrix} \\ &= \begin{pmatrix} 1 & x_1^{(1)} & x_2^{(1)} & x_3^{(1)} & \dots & x_n^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & x_3^{(2)} & \dots & x_n^{(2)} \\ 1 & x_1^{(3)} & x_2^{(3)} & x_3^{(3)} & \dots & x_n^{(3)} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & x_2^{(m)} & x_3^{(m)} & \dots & x_n^{(m)} \end{pmatrix}_{m*(n+1)} \end{aligned} \quad (4)$$

2. $\vec{\theta}$

$$\vec{\theta} = \begin{pmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \theta_3 \\ \vdots \\ \theta_n \end{pmatrix}_{(n+1)*1} \quad (5)$$

3. $h_{\vec{\theta}}(\vec{x})$

$$\begin{aligned} h_{\vec{\theta}}(\vec{x}) &= X * \vec{\theta} \\ &= \begin{pmatrix} 1 & x_1^{(1)} & x_2^{(1)} & x_3^{(1)} & \dots & x_n^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & x_3^{(2)} & \dots & x_n^{(2)} \\ 1 & x_1^{(3)} & x_2^{(3)} & x_3^{(3)} & \dots & x_n^{(3)} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & x_2^{(m)} & x_3^{(m)} & \dots & x_n^{(m)} \end{pmatrix} \begin{pmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \theta_3 \\ \vdots \\ \theta_n \end{pmatrix} \\ &= \begin{pmatrix} 1\theta_0 + x_1^{(1)}\theta_1 + x_2^{(1)}\theta_2 + x_3^{(1)}\theta_3 + \dots + x_n^{(1)}\theta_n \\ 1\theta_0 + x_1^{(2)}\theta_1 + x_2^{(2)}\theta_2 + x_3^{(2)}\theta_3 + \dots + x_n^{(2)}\theta_n \\ 1\theta_0 + x_1^{(3)}\theta_1 + x_2^{(3)}\theta_2 + x_3^{(3)}\theta_3 + \dots + x_n^{(3)}\theta_n \\ \vdots \\ 1\theta_0 + x_1^{(m)}\theta_1 + x_2^{(m)}\theta_2 + x_3^{(m)}\theta_3 + \dots + x_n^{(m)}\theta_n \end{pmatrix}_{m*1} \end{aligned} \quad (6)$$

4. \vec{y}

$$\vec{y} = \begin{pmatrix} y^{(1)} \\ y^{(2)} \\ y^{(3)} \\ \vdots \\ y^{(m)} \end{pmatrix}_{m*1} \quad (7)$$

1.2.2 Cost Function

1. 数值计算形式:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}]^2 \quad (8)$$

2. 矩阵计算形式:

$$J(\theta) = \frac{1}{2m} [h_{\vec{\theta}}(\vec{x}) - \vec{y}]^T [h_{\vec{\theta}}(\vec{x}) - \vec{y}] \quad (9)$$

1.2.3 偏导数 $\frac{\partial J(\theta)}{\partial \theta_j}$ 计算

1. 数值计算形式

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{m} [h_{\theta}(x^{(i)}) - y^{(i)}] x_j^{(i)} \quad (10)$$

2. 矩阵计算形式

$$\nabla J(\theta) = \frac{1}{m} X^T [h_{\vec{\theta}}(\vec{x}) - \vec{y}] \quad (11)$$

1.2.4 梯度下降迭代方式

1. 数值计算形式

$$\begin{aligned}\theta_j &:= \theta_j - \alpha \frac{\partial J(\theta)}{\partial \theta_j} \\ &:= \theta_j - \alpha \frac{1}{m} [h_{\theta}(x^{(i)}) - y^{(i)}] x_j^{(i)}\end{aligned}\tag{12}$$

2. 矩阵计算形式

$$\begin{aligned}\theta &:= \theta - \alpha \nabla J(\theta) \\ &:= \theta - \alpha \frac{1}{m} X^T [h_{\vec{\theta}}(\vec{x}) - \vec{y}]\end{aligned}\tag{13}$$

1.3 Feature Normalization

$$x_i = \frac{x_i - \mu}{\sigma}\tag{14}$$

或

$$x_i = \frac{x_i - \mu}{max - min}\tag{15}$$

1.4 公式法求解 (Normal Equation)

$$\theta = (X^T X)^{-1} X^T y\tag{16}$$

2 逻辑回归(Logistic Regression)

2.1 当只有2个类别时，使用1个分类器

2.1.1 预测函数

1. 数值形式

$$h_{\theta}(x) = \frac{1}{1 + e^{\theta^T x}} \quad (17)$$

2. 矩阵形式

$$h_{\theta}(X) = \frac{1}{1 + e^{X\theta}} \quad (18)$$

2.1.2 Cost Function

1. 数值形式

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m [-y^{(i)} \log h_{\theta}(x^{(i)}) - (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))] \quad (19)$$

2. 矩阵形式

$$J(\theta) = \frac{1}{m} [-y^T \log h_{\theta}(x) - (1 - y^T) \log(1 - h_{\theta}(x))] \quad (20)$$

2.1.3 梯度下降

1. 数值形式

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] x_j^{(i)} \quad (21)$$

迭代方式:

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] x_j^{(i)} \quad (22)$$

2. 矩阵形式

$$\nabla J(\theta) = \frac{1}{m} X^T [h_{\theta}(x) - y] \quad (23)$$

迭代方式:

$$\theta := \theta - \alpha \frac{1}{m} X^T [h_{\theta}(x) - y] \quad (24)$$

2.2 当只有k个类别时，使用k个分类器